

信息学中的概率统计：作业七

截止日期：2025 年 12 月 24 日（周三）下午 3 点前。请务必通过教学网提交电子版。可下课前同时提交纸质版。

与本次作业相关的事宜，请发邮件给我(ruosongwang@pku.edu.cn)，抄送研究生助教叶昊洋(yhyfhs@gmail.com)，以及负责本次作业的本科生助教方嘉聪(jiacong_fang@stu.pku.edu.cn)。

注意：本次作业第六题为**附加题**，正确解决该题目可以得到额外 10% 的分数。

第一题

令总体 X 服从概率密度函数如下的连续分布，其中 $\theta > 0$ 为未知参数，

$$f(x) = \begin{cases} \frac{\theta}{x^2} & x \geq \theta \\ 0 & x < \theta \end{cases}.$$

给定简单随机样本 $X_1, X_2, \dots, X_n$ ，本题中，我们假设样本量 $n > 2$ 。给出 θ 的最大似然估计量 $\hat{\theta}$ ，判断 $\hat{\theta}$ 是否为无偏估计量及渐进无偏估计量，是否为一致估计量，并计算其均方误差。基于 $\hat{\theta}$ ，构造置信水平为 $1 - \alpha$ 的置信区间。

答案：

$$L(\theta) = \prod_{i=1}^n f(x_i) = \frac{\theta^n}{\prod_{i=1}^n x_i^2} \cdot 1_{\theta \leq \min\{x_1, x_2, \dots, x_n\}}.$$

注意到当 $\theta \leq \min\{x_1, x_2, \dots, x_n\}$ 满足时， $L(\theta)$ 关于 θ 为递增函数。因此， θ 的最大似然估计量 $\hat{\theta} = \min\{x_1, x_2, \dots, x_n\}$ 。

当 $x \geq \theta$ ，

$$F_X(x) = \int_0^x f(x)dx = 1 - \theta/x.$$

令 $Y = \min\{X_1, X_2, \dots, X_n\}$ 。

$$P(Y \leq y) = P(\min\{X_1, X_2, \dots, X_n\} \leq y) = 1 - (1 - F_X(y))^n = 1 - (\theta/y)^n.$$

$$E(Y) = \int_0^\infty P(Y \geq y)dy = \theta + \int_\theta^\infty (\theta/y)^n dy = \frac{n}{n-1}\theta.$$

因此， $\hat{\theta} = Y$ 不是无偏估计量，但是渐进无偏估计量。

$$E(Y^2) = \int_0^\infty P(Y^2 \geq y)dy = \theta^2 + \int_{\theta^2}^\infty (\theta/\sqrt{y})^n dy = \frac{n}{n-2}\theta^2.$$

因此，

$$\text{MSE}(\hat{\theta}) = E((\hat{\theta} - \theta)^2) = E(Y^2) + \theta^2 - 2E(Y)\theta = \frac{n}{n-2}\theta^2 + \theta^2 - \frac{2n}{n-1}\theta^2 = \frac{2\theta^2}{(n-1)(n-2)}.$$

注意到 $\lim_{n \rightarrow \infty} \text{MSE}(\hat{\theta}) \rightarrow 0$ ，因此 $\hat{\theta}$ 为一致估计量。

令枢轴量 $G = \hat{\theta}/\theta$ ，对于 $g \geq 1$ ，有 $P(G \leq g) = 1 - g^{-n}$ 。注意到 $P(1 \leq G \leq \alpha^{-1/n}) = 1 - \alpha$ ，因此有

$$P(\alpha^{1/n} \cdot \hat{\theta} \leq \theta \leq \hat{\theta}) = 1 - \alpha.$$

第二题

令总体 $X \sim \text{Exp}(\lambda)$, 其中参数 λ 为未知参数。给定简单随机样本 $X_1, X_2, \dots, X_n$, 在课上, 我们给出了 λ 的一个矩法估计量 $\hat{\lambda}_0 = 1/\bar{X}$ 。本题中, 我们假设样本量 $n > 2$ 。

- (1) 判断 $\hat{\lambda}_0$ 是否为无偏估计量及渐进无偏估计量。提示: 回顾伽玛函数及伽玛分布的定义和性质。
- (2) 基于上一问的结果, 构造 λ 的无偏估计量 $\hat{\lambda}_1$ 。
- (3) 计算 $\hat{\lambda}_1$ 的均方误差, 并判断 $\hat{\lambda}_1$ 是否为一致估计量。
- (4) 给定 $0 < \alpha < 1$, 基于样本均值 $\bar{X}$, 构造统计量 $\hat{\lambda}_L$ 与 $\hat{\lambda}_R$ 使得 $P(\hat{\lambda}_L \leq \lambda \leq \hat{\lambda}_R) = 1 - \alpha$, 也即构造 λ 的置信水平为 $1 - \alpha$ 的置信区间。最终的结果应依赖于 χ^2 分布的分布函数的逆函数 F^{-1} 。(提示: 给出 $2\lambda X_i$ 服从的分布)

答案:

- (1) 注意到 $X \sim \text{Exp}(\lambda) = \Gamma(1, \lambda)$, 因此 $Z = \sum_i X_i \sim \Gamma(n, \lambda)$, 那么 $1/\bar{X} = n/Z$, 进而我们有:

$$E\left(\frac{1}{\bar{X}}\right) = \int_0^\infty \frac{n}{x} \cdot \frac{x^{n-1} \lambda^n e^{-\lambda x}}{\Gamma(n)} dx = \frac{n\lambda}{n-1} \int_0^\infty \frac{x^{n-2} \lambda^{n-1} e^{-\lambda x}}{\Gamma(n-1)} dx = \frac{n\lambda}{n-1}$$

故 $\hat{\lambda}_0$ 不是无偏估计量, 但 $\lim_{n \rightarrow \infty} E(\hat{\lambda}_0) = \lambda$, 故是渐进无偏估计量。

- (2) 考虑如下的估计:

$$\hat{\lambda}_1 = \frac{n-1}{\sum_{i=1}^n X_i} \implies E(\hat{\lambda}_1) = E\left(\frac{n-1}{\sum X_i}\right) = E\left(\frac{(n-1)/n}{\bar{X}}\right) = \frac{n-1}{n} E\left(\frac{1}{\bar{X}}\right) = \lambda$$

故 $\hat{\lambda}_1$ 是 λ 的无偏估计。

- (3) 由于 $\hat{\lambda}_1$ 是无偏估计量, $\text{MSE}(\hat{\lambda}_1) = \text{Var}(\hat{\lambda}_1)$ 。注意到 $Z = \sum_{i=1}^n X_i \sim \Gamma(n, \lambda)$, 则

$$\begin{aligned} E\left(\frac{1}{Z^2}\right) &= \int_0^{+\infty} \frac{1}{z^2} \frac{\lambda^n}{\Gamma(n)} z^{n-1} e^{-\lambda z} dz = \frac{\lambda^n}{\Gamma(n)} \int_0^{+\infty} z^{n-3} e^{-\lambda z} dz \\ &= \frac{\lambda^n}{\Gamma(n)} \frac{\Gamma(n-2)}{\lambda^{n-2}} = \lambda^2 \frac{(n-3)!}{(n-1)!} = \frac{\lambda^2}{(n-1)(n-2)}. \end{aligned}$$

故

$$E(\hat{\lambda}_1^2) = (n-1)^2 E\left(\frac{1}{Z^2}\right) = \frac{n-1}{n-2} \lambda^2.$$

$$\text{MSE}(\hat{\lambda}_1) = \text{Var}(\hat{\lambda}_1) = E(\hat{\lambda}_1^2) - (E(\hat{\lambda}_1))^2 = \frac{n-1}{n-2} \lambda^2 - \lambda^2 = \frac{\lambda^2}{n-2}.$$

当 $n \rightarrow \infty$ 时, $\text{MSE}(\hat{\lambda}_1) \rightarrow 0$, 故 $\hat{\lambda}_1$ 是一致估计量。

- (4) 注意到 $2\lambda X_i \sim \text{Exp}(1/2) = \chi^2(2)$, 因此 $2\lambda n\bar{X} \sim \chi^2(2n)$ 。令枢轴量 $G = 2\lambda n\bar{X}$ 。根据第一问, 有 $G \sim \chi^2(2n)$ 。令 $F(x)$ 为自由度为 $2n$ 的 χ^2 分布的分布函数, 则有

$$P(F^{-1}(\alpha/2) \leq G \leq F^{-1}(1 - \alpha/2)) = 1 - \alpha.$$

因此,

$$\hat{\lambda}_L = \frac{F^{-1}(\alpha/2)}{2n\bar{X}}, \hat{\lambda}_R = \frac{F^{-1}(1 - \alpha/2)}{2n\bar{X}}.$$

第三题

令总体 X 服从概率密度函数如下的连续分布,

$$f(x) = \begin{cases} (\theta+1)x^\theta & 0 < x < 1 \\ 0 & x \notin (0,1) \end{cases},$$

其中 $\theta > 0$ 为未知参数. 给定简单随机样本 $X_1, X_2, \dots, X_n$. 本题中, 我们假设样本量 $n > 2$.

- (1) 计算总体 X 的分布函数 $F_X(x) = P(X \leq x)$.
- (2) 计算总体 X 的数学期望 $E(X)$. 用 $E(X)$ 表示未知参数 θ , 并将 $E(X)$ 替换为样本均值 $\bar{X}$, 从而给出 θ 的矩估计量 $\hat{\theta}_1$.
- (3) 计算 θ 的最大似然估计量 $\hat{\theta}_2$. 判断 $\hat{\theta}_2$ 是否为无偏估计量及渐进无偏估计量. (提示: 给出 $-\ln X_i$ 服从的分布)
- (4) 计算 $\hat{\theta}_2$ 的均方误差, 并判断 $\hat{\theta}_2$ 是否为一致估计量.

答案:

- (1) 当 $0 < x < 1$, $F_X(x) = x^{\theta+1}$. 当 $x \geq 1$, 有 $F_X(x) = 1$.

- (2) 计算期望:

$$E(X) = \int_0^1 x \cdot (\theta+1)x^\theta dx = (\theta+1) \int_0^1 x^{\theta+1} dx = \frac{\theta+1}{\theta+2}. \implies \theta = \frac{2E(X)-1}{1-E(X)}.$$

故矩估计量为

$$\hat{\theta}_1 = \frac{2\bar{X}-1}{1-\bar{X}}$$

- (3) 似然函数为

$$L(\theta) = \prod_{i=1}^n (\theta+1)x_i^\theta = (\theta+1)^n \left(\prod_{i=1}^n x_i \right)^\theta.$$

对数似然函数为

$$\ln L(\theta) = n \ln(\theta+1) + \theta \sum_{i=1}^n \ln x_i.$$

求导得 $\frac{n}{\theta+1} + \sum_{i=1}^n \ln x_i = 0$, 解得最大似然估计量

$$\hat{\theta}_2 = -\frac{n}{\sum_{i=1}^n \ln X_i} - 1.$$

令 $Y_i = -\ln X_i$. 则 $P(Y_i \leq y) = P(-\ln X_i \leq y) = P(X_i \geq e^{-y}) = 1 - (e^{-y})^{\theta+1} = 1 - e^{-(\theta+1)y}$. 故 $Y_i \sim \text{Exp}(\theta+1)$. 令 $T = \sum_{i=1}^n Y_i$, 则 $T \sim \Gamma(n, \theta+1)$. 类似第一题中的计算, 我们有

$$E\left(\frac{1}{T}\right) = \frac{\theta+1}{n-1}. \implies E(\hat{\theta}_2) = nE\left(\frac{1}{T}\right) - 1 = \frac{n\theta+1}{n-1} \neq \theta.$$

故 $\hat{\theta}_2$ 不是无偏估计量. 但 $\lim_{n \rightarrow \infty} E(\hat{\theta}_2) = \theta$, 故是渐进无偏估计量.

(4) 计算均方误差:

$$\begin{aligned} E\left(\frac{1}{T^2}\right) &= \int_0^{+\infty} \frac{1}{t^2} \cdot \frac{t^{n-1}(\theta+1)^n e^{-(\theta+1)t}}{\Gamma(n)} dt = \frac{(\theta+1)^n}{\Gamma(n)} \int_0^{+\infty} t^{n-3} e^{-(\theta+1)t} dt \\ &= \frac{(\theta+1)^n}{\Gamma(n)} \cdot \frac{\Gamma(n-2)}{(\theta+1)^{n-2}} \cdot \int_0^{+\infty} \frac{(\theta+1)^{n-2} t^{n-3} e^{-(\theta+1)t}}{\Gamma(n-2)} dt \\ &= \frac{(\theta+1)^2}{(n-1)(n-2)}. \end{aligned}$$

那么有:

$$\begin{aligned} \text{MSE}(\hat{\theta}_2) &= E((\hat{\theta}_2 - \theta)^2) = \text{Var}(\hat{\theta}_2) + (\text{Bias}(\hat{\theta}_2))^2 \\ &= n^2 \text{Var}\left(\frac{1}{T}\right) + \left(\frac{\theta+1}{n-1}\right)^2 \\ &= n^2 \left[\frac{(\theta+1)^2}{(n-1)(n-2)} - \left(\frac{\theta+1}{n-1}\right)^2 \right] + \frac{(\theta+1)^2}{(n-1)^2} \\ &= \frac{(\theta+1)^2}{(n-1)^2} \left[\frac{n^2}{n-2} + 1 \right] = \frac{(\theta+1)^2(n+2)}{(n-1)(n-2)}. \end{aligned}$$

当 $n \rightarrow \infty$ 时, $\text{MSE}(\hat{\theta}_2) \rightarrow 0$, 故 $\hat{\theta}_2$ 是一致估计量.

第四题

令总体 $X \sim \pi(\lambda)$, 也即参数为 λ 的泊松分布, λ 为未知参数. 给定简单随机样本 $X_1, X_2, \dots, X_n$, 本题中, 我们将考虑 $p = e^{-\lambda}$ 的两个不同的估计量.

(1) 考虑 p 的矩法估计量 $\hat{p}_1 = e^{-\bar{X}}$. 这里, $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 为样本均值. 判断 $\hat{p}_1$ 是否为 $p = e^{-\lambda}$ 的最大似然估计 (简要说明原因, 无需严格证明), 判断 $\hat{p}_1$ 是否为无偏估计量, 渐进无偏估计量, 一致估计量, 并计算 $\hat{p}_1$ 的均方误差. 提示: 参考作业二第四题.

(2) 令 $\hat{p}_2 = \frac{1}{n} \sum_{i=1}^n 1_{X_i=0}$. 这里

$$1_{X_i=0} = \begin{cases} 1 & X_i = 0 \\ 0 & X_i > 0 \end{cases}.$$

判断 $\hat{p}_2$ 是否为无偏估计量, 渐进无偏估计量, 一致估计量, 并计算 $\hat{p}_2$ 的均方误差.

答案:

(1) $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 是 λ 的最大似然估计, 根据最大似然估计的不变性, $e^{-\bar{X}}$ 同样是 $e^{-\lambda}$ 的最大似然估计. $E(\hat{p}_1) = (E(e^{-X_i/n}))^n$, 根据作业二第四题, $E(e^{-X_i/n}) = e^{\lambda(e^{-1/n}-1)}$, 因此 $E(\hat{p}_1) = e^{n\lambda(e^{-1/n}-1)}$. 注意到 $E(\hat{p}_1) = e^{n\lambda(e^{-1/n}-1)} \neq e^{-\lambda}$, 而

$$\lim_{n \rightarrow \infty} e^{n\lambda(e^{-1/n}-1)} = e^{-\lambda},$$

因此 $\hat{p}_1$ 不是无偏估计量, 但 $\hat{p}_1$ 是渐进无偏估计量.

$E(\hat{p}_1^2) = E(e^{-2\bar{X}}) = (E(e^{-2X_i/n}))^n$. 根据作业二第四题, $E(e^{-2X_i/n}) = e^{\lambda(e^{-2/n}-1)}$, 因此 $E(\hat{p}_1^2) = e^{n\lambda(e^{-2/n}-1)}$.

$$\text{MSE}(\hat{p}_1) = E((\hat{p}_1 - e^{-\lambda})^2) = E(\hat{p}_1^2) - 2e^{-\lambda}E(\hat{p}_1) + e^{-2\lambda} = e^{n\lambda(e^{-2/n}-1)} - 2e^{n\lambda(e^{-1/n}-1)-\lambda} + e^{-2\lambda}.$$

注意到

$$\lim_{n \rightarrow \infty} \text{MSE}(\hat{p}_1) = e^{-2\lambda} - 2e^{-2\lambda} + e^{-2\lambda} = 0,$$

因此 $\hat{p}_1$ 为一致估计量。

(2) 注意到 $P(X_i = 0) = e^{-\lambda}$, 因此 $E(\hat{p}_2) = e^{-\lambda}$, 也即 $\hat{p}_2$ 是无偏估计量。因此,

$$\text{MSE}(\hat{p}_2) = \text{Var}(\hat{p}_2) = \frac{1}{n} \cdot e^{-\lambda} \cdot (1 - e^{-\lambda}).$$

由于 $\lim_{n \rightarrow \infty} \text{MSE}(\hat{p}_2) = 0$, 因此 $\hat{p}_2$ 为一致估计量。

第五题 (附加题)

在课上, 我们考虑了下述模型: 给定 n 台游戏机, 第 i 台游戏机的中奖概率为 $0 \leq p_i \leq 1$, 且 p_i 均为未知参数。在第 t 轮中, 选择一台游戏机 $1 \leq i \leq n$, 并观测到结果 $X_t \sim B(1, p_i)$ 。这里 $X_1, X_2, \dots$ 相互独立。

在课上, 我们考虑了下述均匀采样策略: 对每台游戏机进行 N 次观测, 并返回样本均值最大的游戏机。若取 $N = O(\ln n / \epsilon^2)$, 则有 $P(p_o \geq \max p_i - \epsilon) \geq 2/3$, 这里 $1 \leq o \leq n$ 为策略返回的选择。注意到, 该策略需要的总样本数量为 $nN = O(n \ln n / \epsilon^2)$ 。在本题中, 我们将给出更好的算法, 将总样本数量改进至 $O(n / \epsilon^2)$ 。

新的算法共有若干轮。对于第 ℓ 轮 ($\ell \geq 1$), 我们将所有的候选游戏机 (也即未被移除的游戏机) 进行均匀采样, 每台游戏机的采样数量为 $C \cdot \ln(1/\delta_\ell) / \epsilon_\ell^2$, 这里 $C > 0$ 为某个常数, 并计算每台游戏机这一轮采样结果的样本均值。我们将样本均值落在后一半的游戏机移除, 并进入到下一轮。具体来说, 若第 ℓ 轮开始前未被移除的游戏机数量为 n_ℓ , 计算这一轮采样结果的样本均值后, 我们将全部游戏机按照样本均值排序, 并移除均值排序最小的 $\lceil n_\ell / 2 \rceil$ 台游戏机。当只剩一个候选游戏机时, 我们将该台游戏机的编号作为 o 返回。

(1) 对于任意 $\ell \geq 1$, 令 S_ℓ 为第 ℓ 轮结束后的候选游戏机 (也即未被移除的游戏机)。令 $S_0 = \{1, 2, \dots, n\}$ 。对于任意 $1 \leq \ell \leq L$, 证明

$$P\left(\max_{i \in S_\ell} p_i \geq \max_{i \in S_{\ell-1}} p_i - \epsilon_\ell\right) \geq 1 - \delta_\ell.$$

(2) 对于任意 $\ell \geq 1$, 定义合适的 ϵ_ℓ 和 δ_ℓ , 使得 $P(p_o \geq \max p_i - \epsilon) \geq 2/3$, 且算法的总采样次数为 $O(n / \epsilon^2)$ 。

本题为附加题, 正确解决本题可以得到额外 10% 的分数。

答案:

(1) 对于任意 $i \in S_{\ell-1}$, 根据伯努利分布基于 Chernoff bound 的置信区间, 有 $P(|\hat{p}_i - p_i| \leq \epsilon_\ell / 20) \geq 1 - \delta_\ell / 20$, 这里 $\hat{p}_i$ 为本轮采样的样本均值。令 $i_\ell^* = \arg\max_{i \in S_{\ell-1}} p_i$ 。根据期望线性性,

$$E(|\{i \in S_{\ell-1} \mid \hat{p}_i \geq p_i + \epsilon_\ell / 10\}|) = \sum_{i \in S_{\ell-1}} 1_{\hat{p}_i \geq p_i + \epsilon_\ell / 10} \leq |S_{\ell-1}| \cdot \delta_\ell / 20.$$

根据马尔可夫不等式,

$$P(|\{i \in S_{\ell-1} \mid \hat{p}_i \geq p_i + \epsilon_\ell / 10\}| > |S_{\ell-1}| / 3) \leq \delta_\ell / 5.$$

因此, 根据 Union bound,

$$P(|\{i \in S_{\ell-1} \mid \hat{p}_i \geq p_i + \epsilon_\ell / 10\}| \leq |S_{\ell-1}| / 3 \cap \hat{p}_{i_\ell^*} \geq p_{i_\ell^*} - \epsilon_\ell / 10) \geq 1 - \delta_\ell. \quad (1)$$

令 $T_\ell = \{i \in S_{\ell-1} \mid p_i < p_{i_\ell^*} - \epsilon_\ell\}$ 。若 $\max_{i \in S_\ell} p_i < \max_{i \in S_{\ell-1}} p_i - \epsilon_\ell$, 则有 $S_\ell \subseteq T_\ell$ 。然而, 当(1)中的事件发生时, T_ℓ 中满足 $\hat{p}_i \geq p_i + \epsilon_\ell / 10$ 的不同 i 的数量最多为 $n_\ell / 3$ 。对于其余 $i \in T_\ell$, 必然有 $\hat{p}_i < \hat{p}_{i_\ell^*}$ 。因此, 当(1)中的事件发生时, 必然有 $i \in S_{\ell-1} \setminus T_\ell$ 未被删除。

- (2) 令 $\delta_\ell = 1/10 \cdot 2^{-\ell}$, $\epsilon_\ell = \epsilon/10 \cdot (3/4)^\ell$ 。根据 Union bound, 以 $1 - \sum_{\ell \geq 1} 1/10 \cdot 2^{-\ell} \geq 2/3$ 的概率, 第一问中的条件对全部轮 $1 \leq \ell \leq L$ 成立。此时必然有 $p_o \geq \max p_i - \sum_{\ell \geq 1} \epsilon/10 \cdot (3/4)^\ell \geq \max p_i - \epsilon$ 。另外, $|S_\ell| \leq |S_{\ell-1}|/2$, 因此总样本数量为

$$\sum_{\ell \geq 1} |S_{\ell-1}| \cdot O(\ln(1/\delta_\ell)/\epsilon_\ell^2) \leq O\left(\sum_{\ell \geq 1} n/2^\ell \cdot \ell/\epsilon^2 \cdot (16/9)^\ell\right) = O(n/\epsilon^2)。$$