

1 线性代数入门

- 伴随矩阵：将代数余子式矩阵转置后的结果。
- 用伴随矩阵求逆矩阵：再除以原矩阵的行列式值。
- 特征值/特征向量：对于 $x \neq 0$ ，若 $Ax = \lambda x$ 则 λ 是 A 的特征值， x 是 A 的特征向量。
- 对角化： $A = P\lambda P^{-1}$ ， P 的第 i 列为特征值为 λ_i 的特征向量。
- $\det(A) = \det(\lambda) = \prod_{i=1}^n \lambda_i$
- $\det(A^2) = \det(\lambda^2) = \prod_{i=1}^n \lambda_i^2$
- $\text{trace}(A) = \text{trace}(\lambda) = \sum_{i=1}^n \lambda_i$
- $\text{rank}(A) = \lambda$ 对角线非零元素数量。
- 对称矩阵： $A^T = A$
- 正交矩阵： $UU^T = U^T U = I$ ， $|Ux| = |x|$
- 对称矩阵可对角化，且特征值一定为实数，不同特征值的特征向量正交。
- 对称矩阵的正交分解/谱分解： $A = U\lambda U^{-1} = U\lambda U^T$
- 二次型： $f(x) = x^T Ax$ ， A 为对称矩阵。
- 半正定矩阵： $\forall x \neq 0, x^T Ax \geq 0$ ，当且仅当所有特征值都非负。
- 正定矩阵： $\forall x \neq 0, x^T Ax > 0$ ，当且仅当所有特征值都为正。
- 对于半正定矩阵 A ，存在对称矩阵 $B = A^{\frac{1}{2}}$ ， $B^T B = B^2 = A$
- 对于正定矩阵， B 可逆，且 $(B^{-1})^2 = A^{-1}$
- 对于半正定/正定矩阵 A ，满足 $B^T B = A$ 的 B 不唯一。
- 详情可见第零次作业。

2 多维连续随机变量的分布函数和密度函数

- 给定二维随机变量 X, Y 和实数 x, y ，定义 $F(x, y) = P(X \leq x, Y \leq y)$ 为其 **联合分布函数**。
- 有界性： $0 \leq F(x, y) \leq 1, F(-\infty, y) = 0, F(x, -\infty) = 0, F(+\infty, +\infty) = 1$
- 单调性： $x_1 < x_2 \Rightarrow F(x_1, y) \leq F(x_2, y), y_1 < y_2 \Rightarrow F(x, y_1) \leq F(x, y_2)$
- 右连续： $F(x+0, y) = F(x, y), F(x, y+0) = F(x, y)$
- 非负性： $F(a < X \leq b, c < Y \leq d) = F(b, d) - F(a, d) - F(b, c) + F(a, c)$
- 满足以上四条性质等价于其是某个二维随机变量的分布函数。
- 前三条无法推出非负性，反例 $F(x, y) = 1, x + y \geq 0$ 。
- 给定二维随机变量 X, Y ，若存在 $f(x, y) \geq 0$ 使得分布函数可表示为 $F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$ ，则称其为二维连续随机变量， $f(x, y)$ 为其联合密度函数。
- 非负性：定义
- 正则性： $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(u, v) du dv = 1$
- 在 $F(x, y)$ 偏导数存在的点， $\frac{\partial^2 F(x, y)}{\partial x \partial y} = f(x, y)$
- 对于区域 G ， $P((X, Y) \in G) = \int \int_G f(x, y) dx dy$
- 给定一个有界区域 D ， (X, Y) 表示从 D 中均匀取一点坐标，则 $f(x, y) = \frac{1}{S_D}(x, y) \in D, f(x, y) = 0(x, y) \notin D$ 。
- 称 (X, Y) 服从 D 上的 **二维均匀分布**，记为 $(X, Y) \sim U(D)$
- 给定 $F(X, Y)$ ，则 $F_X(x) = F(x, +\infty) = \lim_{y \rightarrow +\infty} F(x, y)$ 为 X 的 **边际分布函数**。
- 给定 $F(X, Y)$ ，则 $F_Y(y) = F(+\infty, y) = \lim_{x \rightarrow +\infty} F(x, y)$ 为 Y 的 **边际分布函数**。
- 给定 $f(x, y)$ ，则 $f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy$ 为 X 的 **边际密度函数**。
- 给定 $f(x, y)$ ，则 $f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$ 为 Y 的 **边际密度函数**。
- $F(x|y) = P(X \leq x|Y = y) = \int_{-\infty}^x \frac{f(u, y)}{f_Y(y)} du$ 为给定 $Y = y$ 条件下 X 的 **条件分布函数**。
- $f(x|y) = \frac{f(x, y)}{f_Y(y)}$ 为给定 $Y = y$ 条件下 X 的 **条件密度函数**。

3 多维连续随机变量的独立性

- 给定二维随机变量 (X, Y) ，分布函数为 $F(x, y)$ ，边际分布函数为 $F_X(x)$ 和 $F_Y(y)$ ，若对于任意实数 x, y 均有 $F(x, y) = F_X(x) \cdot F_Y(y)$ ，则称其相互独立。
- 离散随机变量，即相当于 $P(X = x, Y = y) = P(X = x) \cdot P(Y = y)$
- 连续随机变量，即相当于 $f(x, y) = f_X(x) \cdot f_Y(y)$
- 给定 $f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)} \cdot (\frac{(x-\mu_1)^2}{\sigma_1^2} + \frac{(y-\mu_2)^2}{\sigma_2^2} - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2})}$
- 其中 $\mu_1, \mu_2 \in R, \sigma_1, \sigma_2 > 0, |\rho| < 1$ ，注意 ρ 的取值。
- 则称 X, Y 服从参数为 $\mu_1, \mu_2, \sigma_1, \sigma_2, \rho$ 的 二维高斯/正态分布，记为 $X, Y \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$
- 证明正则性：使用换元法，即 $u' = \frac{x-\mu_1}{\sigma_1} - \rho \cdot \frac{y-\mu_2}{\sigma_2}, v' = \frac{y-\mu_2}{\sigma_2} \cdot \sqrt{1-\rho^2}$
- 因为希望平方括号内是 $u'^2 + v'^2$
- 同时，再把前面的平方项均分，得 $u = \frac{\frac{x-\mu_1}{\sigma_1} - \rho \cdot \frac{y-\mu_2}{\sigma_2}}{\sqrt{1-\rho^2}}, v = \frac{y-\mu_2}{\sigma_2}$
- 即 $f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2}(u^2+v^2)}$
- 算出 *Jacob* 矩阵绝对值为 $\sigma_1\sigma_2\sqrt{1-\rho^2}$
- 随后直接做就行。
- 计算边际密度函数，仍然使用如上换元，得到 $f_X(x) = \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}}, f_Y(y) = \frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{(y-\mu_2)^2}{2\sigma_2^2}}$
- 即若 $X, Y \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ ，则 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$
- 边际分布与参数 ρ 无关，即具有相同边际分布的多维联合分布可以不同，因为可能使用多种 ρ 。
- 条件密度函数，直接使用定义即可。
- 得到 $f(x|y) = \frac{1}{\sqrt{2\pi}\sigma_1\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)} \cdot (\frac{x-\mu_1}{\sigma_1} - \rho \cdot \frac{y-\mu_2}{\sigma_2})^2} = \frac{1}{\sqrt{2\pi}\sigma_1\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)} \cdot (\frac{x-\mu_1 - \rho \cdot \frac{\sigma_1}{\sigma_2}(y-\mu_2)}{\sigma_1})^2}$
- 即给定 $Y = y$ 条件下， $X \sim N(\mu_1 + \rho \cdot \frac{\sigma_1}{\sigma_2}(y - \mu_2), \sigma_1^2(1 - \rho^2))$
- 即给定 $X = x$ 条件下， $Y \sim N(\mu_2 + \rho \cdot \frac{\sigma_2}{\sigma_1}(x - \mu_1), \sigma_2^2(1 - \rho^2))$
- 若它们相互独立，则 $f(x|y) = f_X(x)$

- 等价于 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$
- 即 $\rho = 0$

4 多维连续随机变量的特征数

- 定义: $E(X, Y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) \cdot g(x, y) dx dy$
- 仍然可以证明: $E(X + Y) = E(X) + E(Y)$
- 推广: $E(X_1 + X_2 + \dots + X_n) = E(X_1) + E(X_2) + \dots + E(X_n)$
- 若其相互独立, 则 $E(XY) = E(X) \cdot E(Y)$
- 推广: $X_1, X_2, \dots, X_n$ 相互独立, 则 $E(X_1 X_2 \dots X_n) = E(X_1) E(X_2) \dots E(X_n)$
- 推广: $X_1, X_2, \dots, X_n$ 相互独立, 则 $\text{Var}(X_1 \pm X_2 \pm \dots X_n) = \text{Var}(X_1) + \text{Var}(X_2) + \dots + \text{Var}(X_n)$
- 例: $n \times n$ 矩阵 A 每个元素均服从 $N(0, 1)$, 且不同元素相互独立, 求 $E(\det(A)), E(\text{trace}(A)), E(\text{trace}(A^2))$
- $\det(A) = \sum_{\sigma} (\text{sgn}(\sigma) \cdot \prod_{i=1}^n A_{i, \sigma(i)})$
- 则 $E(\det(A)) = \sum_{\sigma} \text{sgn}(\sigma) \cdot E(\prod_{i=1}^n A_{i, \sigma(i)}) = \sum_{\sigma} \cdot \prod_{i=1}^n E(A_{i, \sigma(i)}) = 0$
- 容易看出 $E(\text{trace}(A)) = 0$
- 根据拆分法, 同样容易看出 $E(\text{trace}(A^2)) = n$
- 给定二维连续随机变量 X, Y 定义 条件数学期望 $E(X|Y = y) = \int_{-\infty}^{+\infty} f(x|y) \cdot x dx$
- 仍然有重期望公式。
- 例: $X \sim \text{Exp}(\lambda), Y \sim U(0, X)$ 计算 $E(Y)$ 和 $\text{Var}(Y)$
- 直接使用重期望公式即可。
- 定义 协方差: $\text{Cov}(X, Y) = E((X - E(X))(Y - E(Y))) = E(XY) - E(X)E(Y)$
- 性质:
 - $\text{Cov}(X, X) = E(X^2) - (E(X))^2$
 - $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
 - $\text{Cov}(aX, bY) = ab \cdot \text{Cov}(X, Y)$

- $\text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)$
- 若 X, Y 相互独立, 则 $\text{Cov}(X, Y) = 0$
- 反之不成立, 具体还是见上述反例。
- $\text{Var}(X_1 + X_2 + \dots + X_n) = \sum_i \sum_j \text{Cov}(X_i, X_j) = \sum_i \text{Var}(X_i) + 2 \sum_i \sum_{j < i} \text{Cov}(X_i, X_j)$
- $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$
- 计算 $X, Y \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 的 $\text{Cov}(X, Y)$
- $\text{Cov}(X, Y) = \iint f(x, y) \cdot (x - \mu_1) \cdot (y - \mu_2) dx dy$
- 仍然照上文换元, 得到 $(x - \mu_1)(y - \mu_2) = \sigma_1 \sigma_2 v(\sqrt{1 - \rho^2} \cdot u + \rho \cdot v)$
- 于是有 $\text{Cov}(X, Y) = \iint \frac{1}{2\pi} e^{-\frac{1}{2}(u^2 + v^2)} \cdot \sigma_1 \sigma_2 v(\sqrt{1 - \rho^2} \cdot u + \rho \cdot v) du dv$
- 即 $\sigma_1 \sigma_2 \iint \frac{1}{2\pi} e^{-\frac{1}{2}(u^2 + v^2)} \cdot v(\sqrt{1 - \rho^2} \cdot u + \rho \cdot v) du dv$
- 拆项发现对 uv 积分为0, 因此得到 $\text{Cov}(X, Y) = \rho \sigma_1 \sigma_2$
- 给定随机变量 X 和 Y , 若 $\sigma(X), \sigma(Y) > 0$ 定义其 相关系数 $\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)}$
- 即, 标准化后的随机变量之相关系数与原随机变量相关系数相等。
- $\text{Corr}(\check{X}, \check{Y}) = \text{Corr}(X, Y)$
- 可以得到, 大于0正相关, 小于0负相关, 等于0不相关。
- 若相互独立, 由于协方差等于0, 因此一定不相关。
- 反过来则不一定, 反例: X 取标准正态分布, $Y = X^2$ 。
- 性质:
 - $|\text{Corr}(X, Y)| \leq 1$ 具体证明见课件。
 - $\text{Corr}(X, Y) = \pm 1 \Leftrightarrow P(Y = aX + b) = 1, a \neq 0$ 具体证明见课件。
 - 注意标准化后的变量, 它们的协方差等于相关系数。
- 例题: 二维正态分布中, X, Y 相互独立当且仅当它们不相关。
- 可以利用前面讲到的性质解决。

5 多维连续随机变量函数的分布

- 给定连续随机变量 X, Y 和函数 $g(x, y)$ 求 $Z = g(X, Y)$ 的概率密度函数。

- **卷积公式**：若 X, Y 相互独立，且 $Z = X + Y$ ，则 $f_Z(z) = \int_{-\infty}^{+\infty} f_X(z - y)f_Y(y)dy$
- 例题： $X \sim N(0, \sigma_1), Y \sim N(0, \sigma_2), X, Y$ 相互独立，求 $Z = X + Y$ 的概率密度函数。
- 此题采用卷积公式会造成极大计算量，可采用后续介绍的正确做法解题！
- 通过计算可以得到 $Z \sim N(0, \sigma_1^2 + \sigma_2^2)$
- 已经知道某个变量服从高斯分布，不需要通过密度变换来增加计算量。
- 推广：若 $X_i \sim N(\mu_i, \sigma_i^2)$ 且相互独立，则 $\sum_{i=1}^n a_i X_i \sim N(\mu_0, \sigma_0^2), \mu_0 = \sum_{i=1}^n a_i \mu_i, \sigma_0^2 = \sum_{i=1}^n a_i^2 \sigma_i^2$
- 特别地，若 X_i 独立同分布，且 $X_i \sim N(0, 1)$ 则 $\sum_{i=1}^n a_i X_i \sim N(0, |a|^2)$,
- 例题： $X \sim \text{Exp}(1), Y \sim \text{Exp}(1), X, Y$ 相互独立，求 $Z = X + Y$ 的概率密度函数。
- 计算得到 $f_Z(z) = \int_{-\infty}^{+\infty} f_X(z - y)f_Y(y)dy = ze^{-z}$
- 也就是 $Z \sim \Gamma(2, 1)$
- 推广： $X \sim \Gamma(\alpha_1, \lambda), Y \sim \Gamma(\alpha_2, \lambda), X, Y$ 相互独立，则 $X + Y \sim \Gamma(\alpha_1 + \alpha_2, \lambda)$
- 例： $X \sim U(0, 1), Y \sim U(0, 1), X, Y$ 相互独立，求 $Z = \max(X, Y)$ 的概率密度函数。
- 建议从分布函数角度出发，即 $P(Z \leq z) = P(X \leq z)P(Y \leq z) = z^2$
- 例： $X \sim U(0, 1), Y \sim U(0, 1), X, Y$ 相互独立，求 $Z = \min(X, Y)$ 的概率密度函数。
- 仍然从分布函数角度出发，即 $P(Z \geq z) = (1 - z)^2$
- 于是， $P(Z \leq z) = 1 - (1 - z)^2$
- 推广： $X_1, X_2, \dots, X_n$ 相互独立，则 $Y = \max(X_1, X_2, \dots, X_n)$ 的分布函数 $F(y)$ 满足 $F_Y(y) = F_{X_1}(y) \cdot F_{X_2}(y) \dots F_{X_n}(y)$
- 推广： $X_1, X_2, \dots, X_n$ 相互独立，则 $Y = \min(X_1, X_2, \dots, X_n)$ 的分布函数 $F(y)$ 满足 $F_Y(y) = 1 - (1 - F_{X_1}(y)) \cdot (1 - F_{X_2}(y)) \dots (1 - F_{X_n}(y))$
- 若连续随机变量 X, Y 的联合密度函数为 $f(x, y)$ ，函数 $u = u(x, y), v = v(x, y)$ 存在连续偏导数且 $x = x(u, v), y = y(u, v)$ 为唯一反函数。
- 则 $U = u(X, Y), V = v(X, Y)$ 的联合密度函数为 $f(x(u, v), y(u, v)) \cdot |J|$
- 其中 $|J|$ 为 **Jacob矩阵**。
- 例题：若 X, Y 相互独立，且 $X \sim N(\mu, 1), Y \sim N(\mu, 1)$ ，计算 $U = X + Y, V = X - Y$ 的联合密度函数。

- 则 $u = x + y, v = x - y, x = \frac{u+v}{2}, y = \frac{u-v}{2}$
- 得到 $|J| = \frac{1}{2}$
- 于是, U, V 的联合密度函数为 $\frac{1}{\sqrt{2\pi}} e^{-\frac{u+v}{2}-\mu^2} \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{u-v}{2}-\mu^2} \cdot \frac{1}{2} = \frac{1}{4\pi} e^{-\frac{1}{4}((u-2\mu)^2+v^2)}$
- 即 $U \sim N(2\mu, 2) V \sim N(0, 2)$ 且 U, V 相互独立。
- 例题: 若连续随机变量 X, Y 相互独立, 计算 $U = XY$ 的概率密度函数。
- 令 $u = xy, v = y$ 得到 $x = \frac{u}{v}, y = v$ 即 $|J| = \frac{1}{|v|}$
- 即其联合密度函数为 $f(\frac{u}{v}, v) \cdot |J| = f_X(\frac{u}{v}) \cdot f_Y(v) \cdot \frac{1}{|v|}$
- 同时, 可以通过积分计算出边际密度函数。
- 可以使用先求分布函数的方法进行验证。

6 多维高斯分布

- 随机变量 $X = (X_1, X_2, \dots, X_n)$, 定义 $E(X) = (E(X_1), E(X_2), \dots, E(X_n))$ 为 X 的 数学期望向量, $\text{Cov}(X) = E((X - E(X))(X - E(X))^T)$ 为 X 的 协方差矩阵。
- 即 $\text{Cov}(X) = \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \dots & \text{Cov}(X_1, X_n) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \dots & \text{Cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_n, X_1) & \text{Cov}(X_n, X_2) & \dots & \text{Var}(X_n) \end{pmatrix}$
- 性质: $\text{Cov}(X)$ 是半正定的对称矩阵。
- 即 $\alpha^T \text{Cov}(X) \alpha = E((\alpha^T (X - E(X)))^2) = \text{Var}(\alpha^T X) \geq 0$
- 给定 $X_1, X_2 \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 计算其协方差矩阵与逆矩阵。
- 由定义得到 $B = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$
- 于是 $\det(B) = (1 - \rho^2)\sigma_1^2\sigma_2^2$
- 接着有 $B^{-1} = \frac{1}{1-\rho^2} \begin{pmatrix} \frac{1}{\sigma_1^2} & -\frac{\rho}{\sigma_1\sigma_2} \\ -\frac{\rho}{\sigma_1\sigma_2} & \frac{1}{\sigma_2^2} \end{pmatrix}$
- 得到 $f(x) = \frac{1}{2\pi(\det(B))^{\frac{1}{2}}} e^{-\frac{1}{2} \cdot (x-\mu)^T B^{-1}(x-\mu)}$
- 结论: n 维高斯分布的联合密度函数为 $f(x) = \frac{1}{(2\pi)^{\frac{n}{2}} \cdot (\det(B))^{\frac{1}{2}}} e^{-\frac{1}{2} \cdot (x-\mu)^T B^{-1}(x-\mu)}$

- 数学期望向量: $\mu \in R^n$
- 协方差矩阵: $B \in R^{n \times n}$, 可逆。
- 记为 $X \sim N(\mu, B)$
- 当 $\mu = 0, B = I_n$
- 则 $f(x) = (2\pi)^{-\frac{n}{2}} \cdot e^{-\frac{1}{2}|x|^2} = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} e^{-\frac{x_i^2}{2}}$
- 性质: $X \sim N(\mu, B), Y = AX + b, AX + b \sim N(A\mu + b, ABA^T)$
- 需要 A 行满秩。
- 证明见课件, 与上述代入法思路大致相同。
- 启发, 满足高斯分布的高维变量作线性变换, 则仍然满足高斯分布。
- 一些例题:
- $X \sim N(\mu, \sigma^2), a \neq 0, Y = aX + b$ 服从的分布。
- X_i 独立同分布, 且 $X_i \sim N(0, 1)$ 求证: $\sum_{i=1}^n a_i X_i \sim N(0, |a|^2)$
- X, Y 相互独立, 且 $X \sim N(\mu, 1), Y \sim N(\mu, 1)$ 计算 $U = X + Y, V = X - Y$ 的联合密度函数。
- 例题: $X \sim N(\mu, B)$ 给出其子向量服从的边际分布, 即 X_i 服从的边际分布。
- 即 $X_i \sim N(\mu_i, B_{i,i})$
- 例题: $X, Y \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 求 $X + Y$ 服从的分布。
- 即 $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2 + 2\rho\sigma_1\sigma_2)$
- 一般多维高斯分布可视为独立同分布标准正态分布线性变换后的结果。
- 即 $X \sim N(0, I_n), Y \sim N(\mu, B)$
- 即 $Y = B^{\frac{1}{2}}X + \mu$
- 同时, $X = B^{-\frac{1}{2}}(Y - \mu)$, 称为白化。
- 对 $Y \sim N(0, I_n)$ 作线性变换 $f(y) = Ay$, 则已经验证 $X \sim N(0, AA^T)$
- 代入得到 $f(x) = \frac{1}{(2\pi)^{\frac{n}{2}} \cdot (\det(AA^T))^{\frac{1}{2}}} e^{-\frac{1}{2} \cdot X^T (AA^T)^{-1} x}$
- 显然地, 变换后的密度函数只和 $B = AA^T$ 有关, 考虑为什么?
- 即其具有旋转不变性: $Y \sim N(0, I_n)$, 若 V 为正交矩阵, 则 $VY \sim N(0, I_n)$

- 几何理解： Y 的概率密度函数正比于 $e^{-\frac{1}{2}|y|^2}$ ，正交变换 V 不改变模长。